

¿Aprovechamos Nuestro potencial de energía eólica?

Juan Manzano [Barona - j.manzano@uniandes.edu.co](mailto:j.manzano@uniandes.edu.co)

Juan Sebastian Perdomo Becerra-js.perdomo2@uniandes.edu.co

Wilson Andrey Lopez Ariza - w.lopeza@uniandes.edu.co

1. Resumen

Basados en la hoja de ruta de transición energética del país y otras naciones, los acuerdos realizados por diferentes países del mundo en acciones para frenar el cambio climático como el desincentivo de fuentes fósiles para producción de energía. La energía eólica se vuelve un actor importante como alternativa, el propósito de este trabajo es utilizar los datos actuales de velocidad de viento, densidad del aire, factores de carga y otras variables todas evaluadas en diferentes rangos de alturas (10,50,100 y 150 metros) para el área de Colombia. A partir de esta información se usan algoritmos no supervisados para poder agrupar zonas y poder identificar áreas hot-spot cuyas características geográficas y condiciones de viento en el tiempo resulten ser viables para la instalación de diferentes turbogeneradores y finalmente poder correlacionar estas agrupaciones de las diferentes zonas con la demanda de energía de los habitantes y si están conectados en el sistema interconectado del país o no.

2. Introducción

Actualmente los países suscritos al acuerdo de Paris toman diferentes acciones para evitar los peores efectos del cambio climático, y lograr reducir las emisiones de dióxido de carbono que contaminan el aire y generan, entre otros, el efecto invernadero y el aumento de la temperatura global (Lima et al., 2020). Una de las líneas de trabajo es disminuir el uso de combustibles fósiles para obtención de energía, en nuestro país tenemos una matriz energética cuya principal fuente es la energía hidroeléctrica pero que esta proporción varía dependiendo de las temporadas de lluvia ya que depende del nivel de los embalses para la producción y como fuentes alternas utilizamos combustibles fósiles como lo podemos notar en la siguiente grafica (Corredor, 2018)




Figura 1. Matriz energética primaria 2015 (Corredor, 2018)

La energía eólica es el aprovechamiento de la energía cinética que tiene el viento por medio de turbinas eólicas de diferentes tamaños conectadas a un generador y cuyo movimiento angular genera electricidad. (Nelson, 2009) Este tipo de energía ha tomado especial relevancia e incrementado

40% su uso en los últimos 20 años en diferentes países, pero no en todas las zonas geográficas del mundo es posible utilizar este tipo de energía ya que se requiere un mínimo de velocidad y densidad de aire a ciertos niveles de altura además de una estacionalidad o constancia en la energía cinética del fluido para que los proyectos sean rentables. En la siguiente grafica podemos resumir las condiciones mínimas óptimas para que los aerogeneradores puedan funcionar.




Figura 2 coeficiente de potencia y desempeño de acuerdo con la velocidad del viento en aerogeneradores convencionales(THUNDER SAID ENERGY the Research Consultancy for Energy Technologies, 2023)

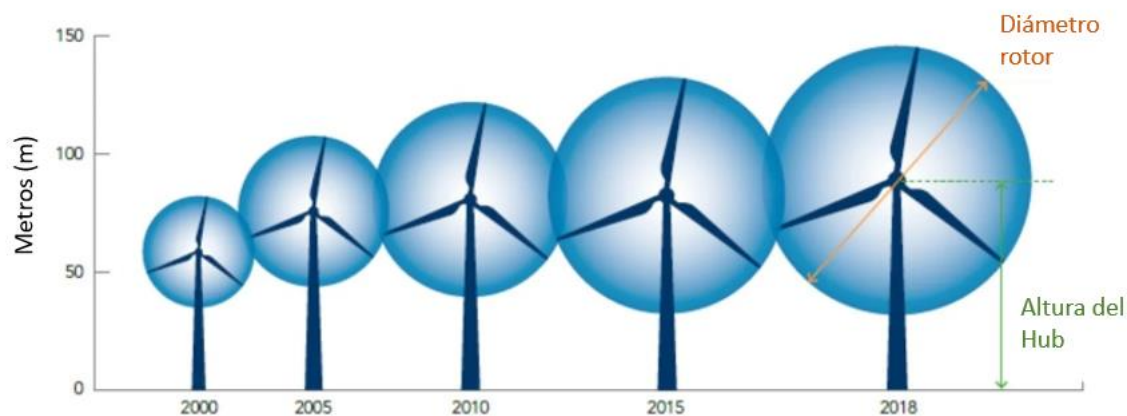


Figura 3 Evolución del tamaño de los aerogeneradores(AWEA, n.d.)

En la figura 2 vemos como dependiendo de la velocidad del viento y la configuración de nuestro aerogenerador vamos a tener diferentes coeficientes de desempeño y una entrega de potencia al sistema energético y en la Figura 3 evidenciamos los diferentes tamaños y rangos de operación que hay actualmente. Por este motivo es de vital importancia analizar las condiciones de viento para la zona geográfica y a diferentes alturas para encontrar lugares factibles para el montaje de este tipo de proyectos (Guerrero Hoyos et al., 2020)

Para el caso de Colombia, pese a que hay proyectos iniciales en el país queremos desarrollar un análisis y agrupación de las diferentes zonas para evidenciar aquellos lugares donde es factible iniciar un proyecto de energía eólica y con potencias teóricas ver el aporte de estas zonas en la demanda de energía en el país además de poder ver si las zonas de factibilidad son aquellas que no se encuentran interconectadas a la red central y pueden generar mayor impacto a sus habitantes.

El área de aprendizaje que abarca este proyecto es tanto reducir la dimensionalidad como agrupamiento o clustering ya que la data con la que vamos a trabajar tiene basta información al ser mapas satelitales y para su tratamiento es necesario reducir dimensionalidad como el objetivo principal es encontrar estas zonas con mayor viabilidad para proyecto de energía renovable

3. Revisión preliminar de antecedentes en la literatura

A nivel mundial existen diferentes investigaciones a partir de mapas satelitales para diferentes zonas del mundo, algunos estudios relevantes y recientes, utilizan métodos de clustering (K-means, EM, Canopy) junto a otros algoritmos no para las revisiones de zonas de factibilidad si no para la unión con datos operativos y buscar la mejor configuración de los aerogeneradores (Chen, 2022). Otros trabajos si realizan un análisis de las zonas en búsqueda de las mejores zonas geográficas, pero para otras longitudes y con resoluciones diferentes a los datos que tenemos (Azhar & Hashim, 2023)(van Vuuren & Vermeulen, 2019). También hay análisis más robustos que evalúan no solo condiciones de viento si no de radiación solar que permitan realizar análisis tecno económicos para proyectos híbridos(solar-eólico) en condiciones geográficas específicas (Jani et al., 2022)

Para el contexto local encontramos un artículo que abarca tanto agrupamiento para energía solar como energía eólica pero que únicamente utilizada el algoritmo de kmeans y no explora diferentes alternativas ni enfoque que puedan dar una mayor profundidad en el análisis (Ramirez-Murillo et al., 2023) o hay otro tipo de análisis para el sector que no utilizan algoritmos de machine learning si no software de análisis espacial o GIS que permiten superponer zonas en formas de mapas pero requieren una supervisión una experiencia considerable en el tema (Guerrero Hoyos et al., 2020; Pinilla, 2008).

En el contexto nacional existe una gran cantidad de documentos que se enfocan en la predicción de condiciones a partir de históricos, estos resultados los podremos usar para nutrir nuestro enfoque y poder evaluar condiciones de agrupamiento y factibilidad no solo con condiciones pasadas si no futuras, para que los resultados sirvan con una visión al futuro y de planeación de proyectos eólicos en el país (Harsh S. Dhiman, 2020; Palomino, 2020)

4. Descripción detallada de los datos

Los datos fueron tomados de <https://globalwindatlas.info/en/area/Colombia> , de acuerdo con el tamaño de las aspas hoy en día utilizamos como fuente principal los data set a 100 m de altura y de apoyo los de 50 y 150 m para análisis adicionales de las condiciones actuales

Para los data set se utilizarán las siguientes variables para la solución del problema

- Wind-speed:Velocidad media por pixel m/s
- Power-density: la potencia media máxima obtenible por área [W/m2]
- Densidad del aire
- Capacity-FactorIEC1: Es la capacidad de carga de acuerdo al tipo de aerogenerador que se distingue en la IEC
- IEC Class - Fatigue Loads: muestra la clase de aerogenerador en términos de velocidad media del viento (clase de aerogenerador I, II, III y S) y parámetros de turbulencia (categoría de turbulencia A+, A, B y C), sin efectos de estela.

Como primeras visualizaciones y análisis obtenemos las primeras graficas de los datos iniciales de los data sets




Figura 4. Velocidad media del viento

Se analizan los datos como Dataframe existen bastantes datos nulos principalmente por la cantidad de datos vacíos que se tienen en la fronteras continental como se ve en la imagen anterior

57.177	-84.754677	-84.752177	-84.749677	-84.747177	-84.744677	-84.742177	...	-66.894677	-66.892177	-66.889677	-66.887177	-66.884677	-66.882177	-66.879677	-66.877177	-66.874677	-66.872177
0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	21.000000	17.000000	13.000000	12.000000	9.000000	8.000000	6.000000	5.000000	3.000000	2.000000
NaN	NaN	NaN	NaN	NaN	NaN	NaN	...	1.788503	1.800239	1.812089	1.819057	1.821631	1.829286	1.824937	1.830089	1.833563	1.826110
NaN	NaN	NaN	NaN	NaN	NaN	NaN	...	0.011236	0.011261	0.013091	0.020861	0.024859	0.018764	0.014754	0.010508	0.011792	0.024621
NaN	NaN	NaN	NaN	NaN	NaN	NaN	...	1.770176	1.775131	1.795943	1.793034	1.802022	1.807986	1.808920	1.814901	1.820274	1.808700
NaN	NaN	NaN	NaN	NaN	NaN	NaN	...	1.781813	1.797096	1.802015	1.800640	1.807059	1.818857	1.813020	1.827052	1.828956	1.817405
NaN	NaN	NaN	NaN	NaN	NaN	NaN	...	1.786605	1.799132	1.806618	1.817657	1.814826	1.827762	1.824393	1.830457	1.837639	1.826110
NaN	NaN	NaN	NaN	NaN	NaN	NaN	...	1.794566	1.809792	1.826152	1.833321	1.816858	1.833517	1.834453	1.834422	1.840207	1.834815
NaN	NaN	NaN	NaN	NaN	NaN	NaN	...	1.812670	1.814113	1.834634	1.853976	1.880135	1.868806	1.844881	1.843614	1.842775	1.843519

	row	col	True	x	y
count	2.154125e+07	2.154125e+07	2.154125e+07	2.154125e+07	2.154125e+07
mean	3.935272e+03	4.051972e+03	4.151445e+00	-7.463600e+01	5.225089e+00
std	1.671049e+03	1.442481e+03	2.480597e+00	3.606203e+00	4.177622e+00
min	3.800000e+01	5.480000e+02	7.615330e-02	-8.339593e+01	-4.234231e+00
25%	2.898000e+03	3.109000e+03	2.310068e+00	-7.699343e+01	2.275769e+00
50%	4.247000e+03	4.178000e+03	3.378509e+00	-7.432093e+01	4.445769e+00
75%	5.115000e+03	5.120000e+03	4.945083e+00	-7.196593e+01	7.818269e+00
max	7.719000e+03	7.157000e+03	1.826077e+01	-6.687343e+01	1.496827e+01

```
data_speed.shape
(21541250, 5)
```

Adicional consulte en el siguiente enlace del código y hub de los datos <https://github.com/jsperdomo/grupo25-aprendizaje-no-supervisado>

5. Propuesta metodológica

Para el plan metodológico estimamos utilizar el siguiente plan de trabajo:

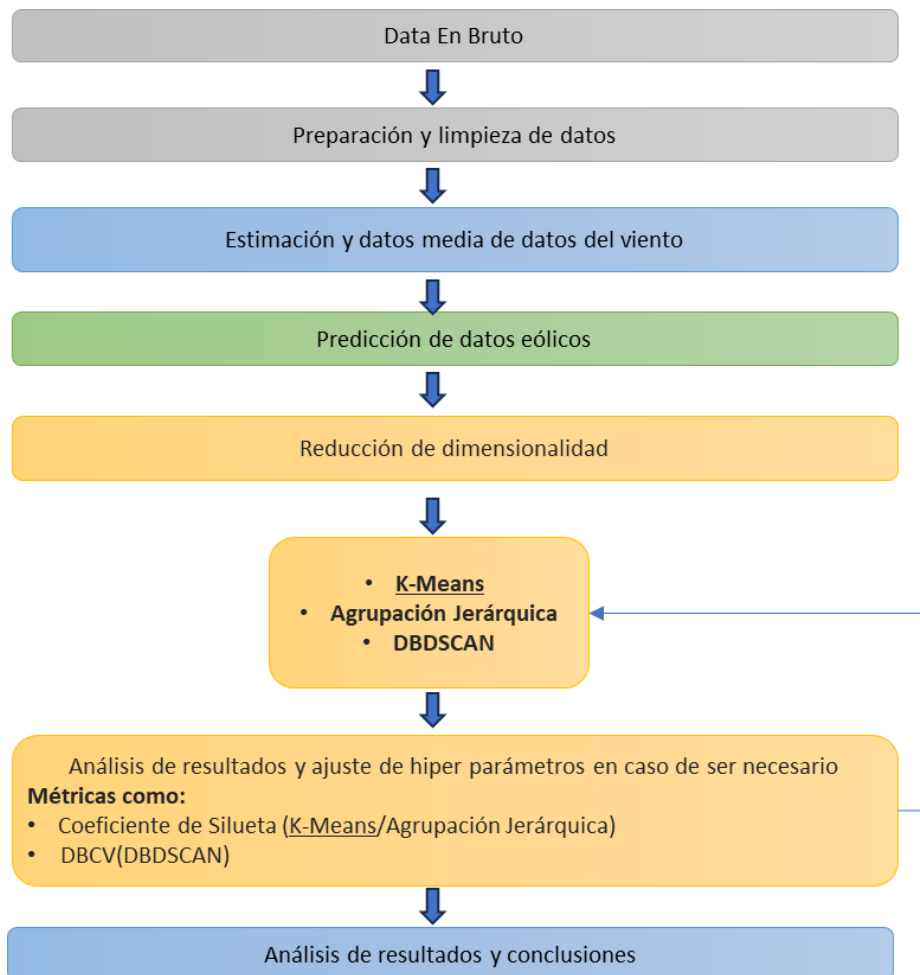


Figura 5 diagrama de metodología

Para el desarrollo de este proyecto se plante usar 3 modelos de algoritmos no supervisados, pero antes de esto con las técnicas aprendidas en el curso se quiere reducir la dimensionalidad y así mismo la complejidad debido al volumen de los datos a tratar. El primero de estos es Kmeans/Kmedias que pese a que nos pida un valor de clúster nos permite fácilmente implementarlo y revisar el comportamiento de los datos ajustando el tipo de distancias que se va a usar (Euclidiana, Pearson entre otras). El segundo modelo lo utilizaremos como un modelo alternativo pese a que sabemos que es un modelo con alto costo computacional, pero nos puede permitir tener información adicional para la cantidad de cluster optima y por último modelo nos ayuda ya que es un modelo flexible y adaptable que no requiere identificar la cantidad grupos y es útil para útil para identificar y tratar con datos de ruido y valores atípicos que con el tipo de datos que vamos a utilizar puede ocurrir

Estos algoritmos los mediremos con diferentes métricas como las ejemplificadas en el diagrama y las aprendidas en el curso con el fin de iterar y refinar los resultados de los diferentes modelos para

poder obtener los mejores resultados posibles y por último analizarlos y solucionar el planteamiento del problema planteado

6. Bibliografía

- THUNDER SAID ENERGY *the research consultancy for energy technologies*. (2023, September 3). <https://Thundersaidenergy.Com/Downloads/Wind-Power-Impacts-of-Larger-Turbines/>.
- AWEA. (n.d.). *Evolution of the Average utility scale turbine*. <https://www.greentechmedia.com/articles/read/the-pros-and-cons-of-ultra-tall-wind-turbine-towers>. Retrieved September 2, 2023, from <https://www.greentechmedia.com/articles/read/the-pros-and-cons-of-ultra-tall-wind-turbine-towers>
- Azhar, A., & Hashim, H. (2023). A Review of Wind Clustering Methods Based on the Wind Speed and Trend in Malaysia. In *Energies* (Vol. 16, Issue 8). MDPI. <https://doi.org/10.3390/en16083388>
- Chen, H. (2022). Cluster-based ensemble learning for wind power modeling from meteorological wind data. *Renewable and Sustainable Energy Reviews*, 167. <https://doi.org/10.1016/j.rser.2022.112652>
- Corredor, G. (2018). Colombia y la transición energética. *Ciencia Política*, 13(25), 107–125. <https://doi.org/10.15446/cp.v12n25.70257>
- Guerrero Hoyos, B. G., Vélez Macías, F. D. J., & Morales Quintero, D. E. (2020). Energía eólica y territorio: sistemas de información geográfica y métodos de decisión multicriterio en La Guajira (Colombia). *Ambiente y Desarrollo*, 23(44). <https://doi.org/10.11144/javeriana.ayd23-44.eets>
- Harsh S. Dhiman. (2020). *Supervised Machine Learning in Wind Forecasting and Ramp Event Prediction*. Elsevier. <https://doi.org/10.1016/C2019-0-03735-1>
- Jani, H. K., Kachhwaha, S. S., Nagababu, G., & Das, A. (2022). Temporal and spatial simultaneity assessment of wind-solar energy resources in India by statistical analysis and machine learning clustering approach. *Energy*, 248, 123586. <https://doi.org/10.1016/j.energy.2022.123586>
- Lima, M. A., Mendes, L. F. R., Mothé, G. A., Linhares, F. G., de Castro, M. P. P., da Silva, M. G., & Sthel, M. S. (2020). Renewable energy in reducing greenhouse gas emissions: Reaching the goals of the Paris agreement in Brazil. *Environmental Development*, 33, 100504. <https://doi.org/10.1016/j.envdev.2020.100504>
- Nelson, V. (2009). *Wind Energy*. CRC Press. <https://doi.org/10.1201/9781420075694>
- Palomino, K. (2020). *Wind Speed Prediction Based on Univariate ARIMA and OLS on the Colombian Caribbean Coast*.

Pinilla, Á. (2008). El poder del viento. *Revista de Ingeniería*, 28, 64–69.
http://www.scielo.org.co/scielo.php?script=sci_arttext&pid=S0121-49932008000200010&lng=en&nrm=iso&tlng=es

Ramirez-Murillo, H., Salazar-Caceres, F., Camargo-Martínez, M. P., & Patiño-Forero, A. A. (2023). Estimación del potencial energético fotovoltaico y eólico mediante agrupamiento no supervisado por k-medias: caso de estudio Universidad de La Salle (Colombia). *Información Tecnológica*, 34(2), 21–30. <https://doi.org/10.4067/s0718-07642023000200021>

van Vuuren, C. Y. J., & Vermeulen, H. J. (2019). Clustering of wind resource data for the South African renewable energy development zones. *Journal of Energy in Southern Africa*, 30(2), 126–143. <https://doi.org/10.17159/2413-3051/2019/v30i2a6316>